

Escopo do Projeto

- **Projeto:** ANEEL — Energia em Risco
 - **Documento:** Escopo do Projeto e Entendimento do Negócio (CRISP-DM Fase 1)
 - **Data de Elaboração:** 09/2026
 - **Versão:** 1.0
-

Sumário

- 1. Dados do Projeto
 - 2. Visão Geral
 - 3. Proposta do Projeto
 - 3.1. Contextualização
 - 3.2. Problema
 - 3.3. Objetivo Geral
 - 3.4. Objetivos Específicos
 - 4. Usuários e Matriz de Stakeholders
 - 5. Dados Necessários e Fontes
 - 6. Hipóteses do Projeto
 - 7. Riscos
 - 8. Fora de Escopo
 - 9. Estrutura de Custos
 - 10. Solução
 - 11. Métricas de Avaliação e Benchmarks de Sucesso
 - 12. Requisitos e Restrições
 - 13. Entregáveis
 - 14. Síntese Executiva
-

1. Dados do Projeto

- **Título:** Projeto ANEEL — Energia em Risco: Análise dos Indicadores DEC/FEC e Predição de Transgressões no Sistema de Distribuição de Energia
 - **Equipe Responsável:** Equipe 14 - Antônio Marcel, Edivaldo Dias, Leonardo Gomes, Leonardo Santos, Vanessa Vilela, Vitor Pires
 - **Metodologia de Gestão:** CRISP-DM e a metodologia ágil Kanban
 - **Repositório Oficial:** Repositório do Projeto | (Branch padrão: develop)
 - **Quadro Kanban:** Kanban_projeto_aneel_equipe14
 - **Período de Execução:** 01/09/2026 a 30/09/2026
-

2. Visão Geral

Este documento consolida a **Fase 1 do CRISP-DM Compreensão do Negócio (Business Understanding)**. Sua finalidade é formalizar o alinhamento estratégico, mapear as dores do setor elétrico e fixar critérios técnicos mensuráveis antes da manipulação dos dados brutos no pipeline de dados.

3. Proposta do Projeto

Elaborar uma solução analítica e preditiva para diagnosticar, monitorar e prever transgressões nos indicadores de continuidade do fornecimento de energia elétrica (DEC e FEC) estipulados pela Agência Nacional de Energia Elétrica (ANEEL).

3.1. Contextualização

A distribuição de energia elétrica no Brasil opera sob regime de concessão pública regulada pela ANEEL. A conformidade dos serviços prestados pelas distribuidoras é fiscalizada segundo os critérios do **PRODIST (Procedimentos de Distribuição de Energia Elétrica no Sistema Elétrico Nacional)**, que estabelece padrões rígidos de qualidade comercial e de continuidade do fornecimento.

A ANEEL acompanha essa qualidade por meio de indicadores regulatórios que permitem medir a duração e a frequência das interrupções percebidas pelos consumidores. Os indicadores centrais utilizados neste projeto são:

- **DEC (Duração Equivalente de Interrupção por Unidade Consumidora):** Mede o tempo médio acumulado, em horas, que os consumidores de um conjunto ficaram sem fornecimento elétrico em um determinado intervalo de tempo.
- **FEC (Frequência Equivalente de Interrupção por Unidade Consumidora):** Mede a quantidade média de vezes em que ocorreram interrupções no fornecimento para os consumidores desse mesmo conjunto.

Para cada conjunto e período de apuração, a ANEEL publica os valores de **Limite DEC** e **Limite FEC**. Quando uma distribuidora apura índices superiores a essas metas ($\text{Apurado} > \text{Limite}$), comete-se uma **transgressão regulatória**. Essa violação obriga a concessionária a creditar compensações financeiras automáticas na fatura dos consumidores afetados, além de elevar o risco de autuações administrativas e comprometer a reputação da companhia perante o mercado e os órgãos de controle.

3.2. Problema

A gestão de continuidade do serviço nas concessionárias opera frequentemente de forma **reativa**: as violações só são diagnosticadas após o fechamento do período regulatório, quando o prejuízo financeiro e as compensações aos consumidores já estão consolidados.

A solução proposta visa apoiar as seguintes decisões críticas de negócio:

- **Transição da Gestão Reativa para Preventiva:** Mudar o foco da apuração retroativa de multas para a antecipação de conjuntos elétricos com risco iminente de transgressão.
- **Mitigação de Passivos Financeiros:** Reduzir o volume de créditos e indenizações diretas pagas aos consumidores por descumprimento de metas regulatórias do PRODIST Módulo 8.
- **Monitoramento Executivo Contínuo:** Fornecer à alta liderança e analistas regulatórios uma visão clara da evolução histórica da conformidade por distribuidora e região.

3.3. Objetivo Geral

Construir uma solução integrada de Análise de Dados e Machine Learning que permita analisar o comportamento histórico dos indicadores DEC e FEC, diagnosticar reincidências de transgressões e estimar a probabilidade de descumprimento dos limites regulatórios futuros em nível de conjunto consumidor.

3.4. Objetivos Específicos

- Consolidar a série histórica (2023–2025) dos dados de continuidade da ANEEL
- Comparar os valores apurados com os limites regulatórios, mapeando taxas de transgressão e gerando ranking dos conjuntos elétricos mais críticos.
- Identificar comportamentos cíclicos e disparidades regionais no desempenho operacional.
- Treinar e avaliar um modelo de Machine Learning supervisionado para classificar o risco de violação (Apurado > Limite) de conjuntos elétricos no horizonte mensal subsequente.
- Disponibilizar os diagnósticos, estimativas de passivo financeiro e scores de risco preditivo em dashboards interativos no Power BI sob modelagem *Star Schema*.

4. Usuários e Matriz de Stakeholders

Quem toma a decisão hoje?

- **Gestores de Distribuidoras (Regulação e Diretoria):** Decidem provisões financeiras, prestam contas à ANEEL e definem estratégias corporativas para cumprimento do contrato de concessão.
- **Operação e Manutenção (O&M):** Decidem a priorização de vistorias técnicas, alocação de equipes de campo e planos de melhoria na rede de distribuição.

Quem é afetado?

- **Consumidores Finais:** Sofrem diretamente com a falta de energia e recebem as compensações financeiras em fatura.
- **Concessionária:** Sofre com o passivo financeiro imediato das compensações e o desgaste de imagem institucional.
- **Times Técnicos (Analistas de Dados/BI e Cientistas de Dados):** São cobrados por diagnósticos rápidos e relatórios confiáveis para justificar desvios aos órgãos de controle.

Matriz de Stakeholders

Stakeholder	Papel na Tomada de Decisão	Dores Principais	Uso da Solução
Gestores de Distribuidoras	Decisor Estratégico	Dificuldade em prever o passivo de multas e falta de visão consolidada do cumprimento contratual	Acompanhamento do dashboard executivo para monitorar taxas de transgressão e projetar custos regulatórios antes do fechamento oficial.

Stakeholder	Papel na Tomada de Decisão	Dores Principais	Uso da Solução
Operação e Manutenção (O&M)	Decisor Operacional	Atuação reativa e falta de critério preditivo para priorizar quais conjuntos elétricos devem receber vistorias preventivas	Utilização do score de risco de Machine Learning para direcionar cronogramas preventivos nos conjuntos com alta probabilidade de estouro
Analistas de Dados/BI	Usuário Analítico	Bases da ANEEL pesadas e despadronizadas; lentidão para atualizar relatórios operacionais no Power BI.	Acesso a dados modelados em Star Schema via Parquet de alta performance, agilizando relatórios e auditorias.
Cientistas de Dados	Usuário Técnico	Falta de dados limpos para modelagem preditiva e necessidade de retreino periódico dos modelos.	Pipeline reproduzível com histórico sazonal e métricas padronizadas

5. Dados Necessários e Fontes

Dados Necessários

* Dados dos indicadores: DEC e FEC apurados, limites regulatórios mensais/anuais, valores de compensação financeira e identificador da distribuidora.

- Dados complementares: Código e nome do conjunto de unidades consumidoras, quantidade de clientes atendidos, região geográfica/UF, subestação de atendimento e histórico cadastral.
- Dados derivados: Médias móveis, taxas de variação mensal, contagem de reincidência de violações consecutivas, índices de sazonalidade e score preditivo de risco de transgressão.

Fonte de Dados

Os dados são de origem pública e extraídos do **Portal de Dados Abertos da ANEEL** e do arcabouço normativo do **PRODIST**. Para fins de análise, o conjunto de dados será limitado a um período de 3 anos (2023-2026):

Entidade / Recurso	Fonte Oficial	Periodicidade / Granularidade	Uso no Projeto
Indicadores Coletivos de Continuidade (DEC e FEC)	Portal de Dados Abertos da ANEEL	Mensal / Anual por Conjunto Elétrico	Dados brutos de DEC e FEC (apurado e limites regulatórios) para métricas de BI e alvo do ML.
Interrupções de Energia Elétrica	Portal de Dados Abertos da ANEEL	Por evento / Ocorrência	Mapeamento da tipologia de causas

Entidade / Recurso	Fonte Oficial	Periodicidade / Granularidade	Uso no Projeto
nas Redes de Distribuição			das quedas (acidentais, programadas, expurgos regulatórios).
Regras e Parâmetros Regulatórios	<u>ANEEL — PRODIST Módulo 8</u>	Regulatório / Estático	Fórmulas conceituais de transgressão e parâmetros para cálculo da proxy de compensações financeiras.

Armazenamento e Formato

Arquivos originais em .csv/.parquet mantidos fora do versionamento do Git, processados via DuckDB e salvo como Parquet otimizado na pasta data/interim/ e data/processed/.

Privacidade e LGPD: 100% dos dados são operacionais e anonimizados na fonte pela ANEEL, sem exposição de dados pessoais ou faturas individualizadas.

6. Hipóteses do Projeto

- **Hipótese 01** - Conjuntos com histórico crônico de transgressão de DEC e FEC apresentam probabilidade significativamente maior de ultrapassar os limites regulatórios nos períodos seguintes.
- **Hipótese 02** - Interrupções não programadas possuem maior impacto no tempo acumulado de desabastecimento (DEC) em comparação às paradas programadas para manutenção.
- **Hipótese 03** - Existe sazonalidade nas interrupções, com meses e regiões mais propensos à piora da continuidade.
- **Hipótese 04** - O volume de unidades consumidoras atendidas e o perfil geográfico do conjunto influenciam diretamente o desempenho dos indicadores de continuidade.
- **Hipótese 05** - O histórico recente de DEC, FEC e do volume de interrupções pode ser utilizado para prever o risco de transgressão regulatória no período subsequente.

7. Riscos

1. Risco de Dados

- Dados faltantes ou nulos, com ausência de registros pontuais em limites ou apurações de conjuntos desativados/reestruturados.
- Inconsistências temporais e cadastrais, com mudança de identificador do conjunto elétrico ou alterações de metodologia cadastral ao longo dos anos.
- Granularidade desigual, contendo conflito entre dados agregados mensalmente (DEC/FEC) e dados por ocorrência (interrupções individuais).

2. Risco de Modelagem e Machine Learning

- Volume de meses em conformidade muito superior ao de transgressões, induzindo o modelo a prever sempre a classe majoritária.
- O algoritmo memorizar o comportamento (overfitting) de distribuidoras específicas sem conseguir prever o risco em novas regiões.
- Uso de acurácia global em vez de métricas mais robustas (Recall, PR-AUC e F1-Score).

3. Risco de Projeto e Negócio

- Gerar *insights* estatísticos avançados, mas que não auxiliam a tomada de decisão prática da equipe de manutenção.
 - Confundir correlação de variáveis operacionais com causalidade regulatória.
 - Não considerar alterações ou revisões tarifárias/metaprovadas pela ANEEL no período.
-

8. Fora de Escopo

- Não serão manipulados dados individualizados por consumidor, garantindo conformidade com a LGPD.
 - A solução não definirá reajustes de tarifa de energia nem estratégias de cobrança ou faturamento.
 - O projeto se encerra na entrega do modelo validado com previsões salvas em lote e dashboard no Power BI.
 - Não serão integradas APIs meteorológicas em tempo real e arquivos da BDGD (redes elétricas/postes).
 - Ausência de banco de dados corporativo dedicado ou cluster em nuvem (arquitetura desacoplada baseada em arquivos Parquet).
-

9. Estrutura de custos

- **Fontes de Dados:** Gratuitas (Portal de Dados Abertos da ANEEL sob licença pública).
 - **Infraestrutura Computacional:** Execução em máquinas locais dos membros da equipe e instâncias gratuitas em nuvem (Google Colab / GitHub).
 - **Esforço Humano (Custo Operacional):** Dedicção de 6 membros ao longo do ciclo do projeto, distribuídos entre engenharia de dados, modelagem preditiva, construção do dashboard e documentação.
 - **Manutenção Futura (Evolutivo):** Esforço periódico estimado em poucas horas/mês para reexecução do script de download, atualização de novos meses da ANEEL e retreino semestral do modelo.
-

10. Solução

- Pipeline automatizado em Python/DuckDB para ingestão, tratamento de dados nulos, padronização de esquemas, criação de variáveis temporais (médias móveis, defasagens/lags e tendências) e exportação no formato `.parquet`.
- Análise exploratória de Dados (EDA), com identificação de padrões, tendências e possíveis relações entre variáveis.

- Modelo supervisionado de classificação tabular executado em lote (*batch*), gerando scores de probabilidade de violação regulatória para cada conjunto elétrico no período subsequente.
 - Painel interativo em Power BI.
-

11. Métricas de Avaliação e Benchmarks de Sucesso

1. Qualidade e Integridade dos Dados:

- **Percentual de Valores Ausentes:** Registros sem preenchimento em campos críticos (DEC, FEC, Limites e IDs de Conjunto) inferiores a **1%**.
- **Consistência Temporal e Duplicidade:** Manter **0%** de duplicidade na granularidade chave (Conjunto + Mês/Ano) em todo o histórico de 2023 a 2026.
- **Taxa de Registros Válidos:** Pelo menos **98%** das linhas em conformidade com as regras operacionais da ANEEL.

2. Eficácia da Análise e Visualização:

- **Cobertura Cadastral:** **100%** das distribuidoras e conjuntos elétricos da base processada navegáveis no painel.
- **Identificação de Concentração:** Mapeamento quantitativo comprovando a concentração de horas excedentes nos conjuntos mais críticos.
- **Performance e Navegação:** Painel em Power BI estruturado em *Star Schema* com filtros dinâmicos e tempo de resposta inferior a **5 segundos** por interação.

3. Desempenho do Modelo Preditivo (Machine Learning):

- **Recall (Sensibilidade) > 75%:** Capacidade de antecipar a maioria das transgressões reais antes do fechamento do mês, minimizando muitas surpresa.
- **Precisão > 60%:** Garantir que pelo menos 3 a cada 5 alertas emitidos pelo modelo correspondam a problemas reais, evitando deslocamento inútil de equipes.
- **F1-Score (> 0.65 a 0.70):** Balanço harmônico entre capturar o risco regulatório e não saturar a operação com alarmes falsos.
- **PR-AUC e ROC-AUC (> 0.80):** Capacidade geral do modelo de ordenar e separar corretamente os conjuntos de alto risco dos conjuntos estáveis.
- **Matriz de Confusão Calibrada:** Ajuste do limiar de decisão (*threshold*) priorizando a redução expressiva de falsos negativos (transgressões não previstas).

4. Impacto e Acionabilidade de Negócio

- **Foco no Top Risco (Lift Operacional):** O modelo deve concentrar pelo menos 60% das transgressões reais do mês seguinte dentro dos 20% dos conjuntos sinalizados com maior probabilidade de violação.
- **Priorização Acionável:** Geração de um ranking mensal dos conjuntos elétricos com maior urgência de vistoria preventiva.
- **Simulação de Redução de Passivos:** Quantificação financeira das compensações regulatórias potencialmente evitadas caso as manutenções atuem a tempo nos conjuntos sinalizados.

12. Requisitos e Restrições

1. Requisitos Funcionais (RF):

- **RF01:** O pipeline deve consolidar os dados mensais de continuidade (DEC e FEC) de 2023 a 2026.
- **RF02:** O sistema deve calcular o indicador booleano de transgressão ($\text{Apurado} > \text{Limite}$) e a margem de desvio relativo para cada conjunto/mês.
- **RF03:** A camada de dados deve alimentar o Power BI com um modelo dimensional (*Star Schema*) contendo tabelas fato e dimensão documentadas.
- **RF04:** O modelo de Machine Learning deve gerar uma coluna contendo o *Score de Risco* (probabilidade entre 0 e 1) de descumprimento para o período $t+1$.

2. Requisitos Não Funcionais (RNF):

- **RNF01:** Scripts de dados e modelagem versionados no Git com arquivo `requirements.txt` e ambiente virtual configurado.
- **RNF02:** Processamento de arquivos pesados via DuckDB em disco, sem exceder 4 GB de memória RAM local.
- **RNF03:** Estrita aderência à LGPD, não utilizando registros de consumo ou dados pessoais identificáveis.

13. Entregáveis

1. Repositório de Código Documentado (GitHub):

- Código de ingestão e transformação automatizado em DuckDB/Python.
- Pipeline de treino, validação e inferência em lote de Machine Learning.
- Arquivo `README.md` com instruções detalhadas de reprodução do ambiente.

2. Camada de Dados Otimizada (Data Lake Local):

- Bases consolidadas em Apache Parquet nas pastas `data/interim/` e `data/processed/` (*Star Schema* e dataset pronto para treino de ML).

3. Análise Exploratória de Dados (EDA):

- Notebooks documentados com o diagnóstico descritivo do DEC e FEC, análise de sazonalidade, concentração de queixas e validação estatística das hipóteses levantadas.

4. Dashboard Executivo e Operacional (Power BI):

- Relatório interativo `.pbix` integrando diagnóstico histórico de DEC/FEC, análise de causas e o score preditivo de transgressão.

5. Relatório Técnico e Apresentação Executiva:

- Síntese metodológica contendo a validação das hipóteses, métricas do modelo preditivo e recomendações práticas de negócio.
-

14. Síntese Executiva

Canvas do Problema

Equipe 14: Antonio Marcel, Edivaldo Dias, Leonardo Gomes, Leonardo Oliveira, Vanessa Vilela, Vitor Pires

Problema: “Como utilizar dados públicos da ANEEL para analisar padrões de continuidade do fornecimento de energia elétrica, gerar análises confiáveis e desenvolver modelos de Machine Learning capazes de prever o risco de piora da qualidade do serviço ou de ultrapassagem dos limites regulatórios?”

